

Universidade Federal de Minas Gerais (UFMG) Alunos: Lucas Affonso Pires, John Wesley Otaciano Costa, Emmanuel Magalhães Figueiredo, Bernardo Venâncio Cunha.

Grupo: 10

Proposta de Projeto: Mineração de Dados

1. Contexto e Motivação

A análise de dados no setor fitness permite identificar comportamentos e necessidades de diferentes perfis de praticantes. No entanto, a aplicação de modelos analíticos sobre dados de saúde exige cautela quanto à procedência dos dados e às premissas dos algoritmos. Este projeto busca aplicar técnicas de agrupamento para explorar como características biométricas e de rotina se organizam naturalmente, servindo como um exercício de mineração de dados em um domínio de grande interesse social e pessoal para o grupo.

2. Objetivos

O objetivo central é realizar uma análise exploratória e não supervisionada para segmentar praticantes de exercícios. Os objetivos específicos são:

- Caracterizar os perfis que emergem dos dados em termos de intensidade, frequência e biometria.
- Avaliar a coesão dos grupos formados frente às limitações de algoritmos de agrupamento com variáveis mistas.
- Discutir as implicações de se trabalhar com dados de origem sintética no contexto de mineração de dados.

3. Problema a ser Investigado

Quais perfis de praticantes de exercícios emergem dos dados disponíveis e de que forma esses grupos se diferenciam sistematicamente em termos de intensidade de treino, frequência semanal e características biométricas (como idade e IMC)?

4. Método Principal

O projeto utilizará **Agrupamento (Clustering)**. Devido à natureza mista do dataset (variáveis contínuas e categóricas), utilizaremos o algoritmo **K-Prototypes** ou o **K-Means** precedido por uma etapa rigorosa de **One-Hot Encoding** para as variáveis categóricas (como gênero e nível de experiência). Reconhecemos as limitações do K-Means quanto à suposição de clusters esféricos e buscaremos validar os resultados via Coeficiente de Silhueta e análise de variância entre clusters.

5. Dados Pretendidos

Utilizaremos o *Gym Members Exercise Dataset* (Kaggle). O dataset possui aproximadamente 1000 registros, atendendo ao limite mínimo da especificação. É importante ressaltar como **limitação explícita** que a base possui indícios de ser sintética ou semi-sintética, carecendo de documentação sobre coleta real. Assim, os padrões descobertos serão tratados como "perfis emergentes dos dados" e não necessariamente como comportamentos biológicos reais, servindo primordialmente para a validação do fluxo metodológico de mineração.

6. Metodologia Preliminar

- **Data Understanding:** Identificação de variáveis contínuas e categóricas e análise de distribuições.
- **Data Preparation:** Normalização de variáveis numéricas (*Min-Max Scaling*) para equilibrar pesos e transformação de variáveis categóricas via *One-Hot Encoding*. Tratamento da possível natureza sintética através de análise de outliers.
- **Modeling:** Execução de algoritmos de agrupamento. O número de clusters será definido pelo Método do Cotovelo (*Elbow Method*) e refinado pela análise de Silhueta.
- **Evaluation:** Interpretação dos centroides para descrever os perfis em termos de intensidade e biometria. Comparação entre algoritmos (ex: K-Means vs DBSCAN) para verificar a estabilidade dos grupos.
- **Análise de Limitações:** Discussão crítica sobre como a natureza dos dados e o caráter transversal (não longitudinal) do dataset impedem inferências sobre sucesso ou evolução temporal.

7. Diretrizes de IA Responsável

1. Explicabilidade:

- a. *Por que é pertinente:* Em modelos de agrupamento, o "porquê" de um indivíduo pertencer a um cluster é fundamental para que a análise tenha valor prático.
- b. *Como será incorporada:* Utilizaremos técnicas de interpretação de centroides e visualizações de importância de atributos para explicar quais variáveis foram determinantes para a separação dos perfis (ex: a frequência de treino foi mais decisiva que a idade para separar o Grupo A do B?).
- c. *Impactos/Trade-offs:* Pode exigir a redução da dimensionalidade do modelo para manter a interpretabilidade humana, possivelmente sacrificando uma separação matemática mais fina.

2. Justiça e Viés:

- a. *Por que é pertinente:* Dados sintéticos podem amplificar estereótipos ou correlações irreais (ex: associar força excessiva apenas a um gênero devido a um erro na geração dos dados).
- b. *Como será incorporada:* Realizaremos testes de sensibilidade para verificar se o algoritmo está isolando grupos protegidos (gênero/idade) de forma desproporcional e injustificada.
- c. *Impactos/Trade-offs:* Se um viés for detectado, o grupo poderá optar por remover a variável sensível da etapa de modelagem, mesmo que isso diminua o poder de segmentação do algoritmo.

8. Referências Iniciais

- Huang, Z. (1998). Extensions to the k-means algorithm for clustering large data sets with categorical values. *Data Mining and Knowledge Discovery*.
- Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining.
- Kaggle. (2024). *Gym Members Exercise Dataset*. (Reconhecido como recurso para fins acadêmicos com ressalvas de procedência).