

MINERAÇÃO DE PERFIS DE PRATICANTES DE EXERCÍCIOS

Análise Exploratória e Agrupamento — Gym Members Dataset

Lucas A. Pires · John Wesley O. Costa · Emmanuel M. Figueiredo · Bernardo V. Cunha

GRUPO 10 — Universidade Federal de Minas Gerais (UFMG)

Disciplina: Mineração de Dados · 2025/2026

Dataset	Método Principal	Diretrizes IA	Entrega
Gym Members Exercise Dataset (Kaggle) 973 registros · 15 atributos	Agrupamento K-Means + DBSCAN PCA (visualização)	Justiça e Viés Explicabilidade	Relatório Final Grupo 10 Junho 2026

Resumo: Este relatório documenta o projeto de Mineração de Dados do Grupo 10 (UFMG/DCC), cujo objetivo foi identificar perfis latentes de praticantes de exercícios a partir de dados biométricos e de rotina. Aplicamos a metodologia CRISP-DM, utilizando K-Means e DBSCAN como métodos principais de agrupamento, com PCA para visualização bidimensional. Três clusters foram identificados — Iniciantes, Intermediários e Avançados — com separação estatisticamente coerente. Adicionalmente, incorporamos explicitamente as diretrizes de IA responsável de Justiça e Viés e Explicabilidade, operacionalizadas em análises quantitativas ao longo do pipeline.

1 FUNDAMENTAÇÃO E TRABALHOS RELACIONADOS

1.1 Contexto e Motivação

A crescente disponibilidade de dados de atividade física e biometria criou oportunidades para a aplicação de técnicas de Mineração de Dados no setor de saúde e fitness. Identificar perfis de praticantes de exercícios de forma não supervisionada permite personalizar recomendações de treino, detectar comportamentos atípicos e embasar decisões em academias e aplicativos de saúde, sem depender de rótulos pré-definidos por especialistas.

A análise de agrupamento — ou *clustering* — é amplamente utilizada para descoberta de estrutura latente em dados de saúde. Em particular, algoritmos baseados em distância euclidiana, como o K-Means, são amplamente adotados pela interpretabilidade dos centroides resultantes (Jain, 2010). Para dados com ruído ou de geometria irregular, o DBSCAN oferece uma alternativa baseada em densidade que detecta automaticamente outliers (Ester et al., 1996).

1.2 Trabalhos Relacionados

Os fundamentos metodológicos deste projeto apóiam-se em quatro frentes:

- **K-Means e Agrupamento Particionado:** MacQueen (1967) propôs o algoritmo K-Means original; Jain (2010) realizou uma extensa revisão de cinquenta anos de clustering demonstrando sua robustez em dados contínuos normalizado. Para dados mistos, Huang (1998) propôs o K-Prototypes, considerado na proposta original do projeto, mas substituído pelo K-Means após One-Hot Encoding, dado o baixo número de variáveis categóricas.
- **DBSCAN e Detecção de Outliers:** Ester et al. (1996) introduziram o DBSCAN como algoritmo de agrupamento baseado em densidade, capaz de identificar clusters de formato arbitrário e marcar pontos de baixa densidade como ruído. Schubert et al. (2017) revisaram melhorias e aplicações, confirmando sua utilidade para detecção de anomalias.
- **CRISP-DM como Framework de Processo:** Wirth e Hipp (2000) formalizaram o Cross-Industry Standard Process for Data Mining (CRISP-DM), adotado neste projeto como guia metodológico. A estrutura iterativa permite revisão crítica de decisões de modelagem à luz dos objetivos de negócio.
- **IA Responsável em Saúde e Fitness:** Barocas, Hardt e Narayanan (2019) sistematizaram métricas de justiça algorítmica em *Fairness and Machine Learning*, incluindo o Disparate Impact Ratio (regra dos 4/5) aplicado neste projeto. Doshi-Velez e Kim (2017) discutem explicabilidade como requisito de confiança em sistemas de IA aplicados a decisões que afetam pessoas.

2 METODOLOGIA

2.1 Framework CRISP-DM

O projeto seguiu o framework CRISP-DM em cinco fases iterativas, com retorno à fase anterior sempre que novos achados exigiram revisão de decisões anteriores:

Fase CRISP-DM	Atividade Principal	Principal Decisão
Business Understanding	Definição do problema de segmentação e das perguntas de investigação	Método principal: Agrupamento não supervisionado
Data Understanding	EDA: distribuições, correlações, análise de outliers e gênero	Identificação de correlações altas: $r=0,91$ e $r=0,85$
Data Preparation	Normalização Z-score, remoção de redundâncias, seleção de 9 features	Exclusão de Session_Duration e Weight (redundantes)
Modeling	K-Means ($k=2..10$) + DBSCAN ($\epsilon=0,5-2,0$; MinPts=3–10)	$k=3$ pelo equilíbrio entre coesão e interpretabilidade
Evaluation	Silhouette, DBI, análise de centroides, fairness, explicabilidade	DI=0,63 no DBSCAN — atenção ao viés de gênero

Tabela 1 — Fases do CRISP-DM aplicadas ao projeto.

2.2 Estratégia de Avaliação

Três dimensões foram avaliadas de forma integrada:

- **Métricas internas de clustering:** Silhouette Score (coesão intra-cluster e separação inter-cluster), Davies-Bouldin Index (DBI — razão entre dispersão interna e distância entre centroides) e WCSS/Inércia (Método do Cotovelo).
- **Validação de domínio:** Comparação cruzada dos clusters com a variável Experience_Level do dataset, que serve como proxy de verdade de campo para verificar se os grupos descobertos correspondem a perfis reconhecíveis.
- **Avaliação de IA Responsável:** Análise de distribuição demográfica (gênero) dentro de cada cluster (K-Means) e na classificação como outlier (DBSCAN), com cálculo do Disparate Impact Ratio conforme a regra dos 4/5.

3 COMPREENSÃO E PREPARAÇÃO DOS DADOS

3.1 Descrição do Dataset

O Gym Members Exercise Dataset foi obtido no Kaggle e contém 973 registros de membros de academia com 15 atributos cobrindo biometria, parâmetros cardiovasculares e rotina de treino. O dataset está completo (0 valores ausentes).

Atributo	Tipo	Descrição	Estatística-Chave
Age	Numérico	Idade (anos)	Média 38,7 · DP 12,2
Gender	Categórico	Gênero	511 M / 462 F (52,5% / 47,5%)

Atributo	Tipo	Descrição	Estatística-Chave
BMI	Numérico	Índice de Massa Corporal	Média 24,9 · DP 6,7
Fat_Percentage	Numérico	% Gordura Corporal	Média 24,9 · DP 9,6
Max_BPM	Numérico	Frequência cardíaca máxima	Média 179,8 · DP 24,6
Avg_BPM	Numérico	BPM médio durante treino	Média 143,9 · DP 14,6
Resting_BPM	Numérico	BPM em repouso	Média 62,2 · DP 14,7
Calories_Burned	Numérico	Calorias queimadas/sessão	Média 905,4 · DP 305,4
Session_Duration	Numérico	Duração da sessão (h)	$r=0,91$ com Calories — excluído
Workout_Frequency	Numérico	Dias de treino/semana	Média 3,5 · DP 0,9
Experience_Level	Ordinal	Nível de experiência (1–3)	376 (1) / 406 (2) / 191 (3)
Workout_Type	Categórico	Tipo de treino	Strength 26% · Cardio 26% · Yoga 25% · HIIT 23%
Weight (kg)	Numérico	Peso corporal	$r=0,85$ com BMI — excluído
Water_Intake	Numérico	Consumo de água (L)	Baixo poder discriminativo — excluído

Tabela 2 — Descrição dos atributos do Gym Members Exercise Dataset.

3.2 Descobertas da Análise Exploratória (EDA)

- **Correlações altas detectadas:** Session_Duration × Calories_Burned ($r=0,91$) e Weight × BMI ($r=0,85$). Incluir ambas as variáveis de cada par envia a distância euclidiana duplamente para o mesmo conceito.
- **Distribuição de gênero balanceada:** 52,5% masculino / 47,5% feminino, sem dominância severa que pudesse distorcer análises de fairness.
- **Calorias por tipo de treino:** HIIT e Strength apresentam mediana e amplitude superiores, enquanto Yoga tem menor dispersão — distribuição esperada fisicamente.
- **Experience_Level como variável discreta:** Os três níveis (1, 2, 3) têm contagens balanceadas (376, 406, 191), porém sua natureza ordinal discretizada pode criar fronteiras artificialmente nítidas no espaço de features.
- **Ausência de outliers univariados extremos:** Nenhuma variável apresentou valores clinicamente implausíveis, mas o DBSCAN revelou 34,2% de pontos multivariadamente atípicos.

3.3 Preparação dos Dados

Três decisões de preparação foram tomadas com justificativa técnica explícita:

Decisão	Justificativa	Impacto
Remoção de Session_Duration e Weight	Correlação > 0,85 com Calories e BMI — redundância que domina a distância euclidiana	Reduz viés de feature duplicada
Manutenção de Gender e Workout_Type fora das features	One-Hot Encoding em apenas 2 variáveis de baixa cardinalidade poderia criar dimensões com pouca variância	Permite análise de fairness pós-hoc sem contaminar o clustering
StandardScaler (Z-score) em todas as features numéricas	K-Means e DBSCAN são sensíveis à escala; Calories_Burned (≈900) dominaria sobre BMI (≈25) sem normalização	Features com diferentes magnitudes tratadas com peso igual

Tabela 3 — Decisões de preparação de dados com justificativas.

O conjunto de features finais utilizado no clustering foi: **Age, BMI, Fat_Percentage, Max_BPM, Avg_BPM, Resting_BPM, Calories_Burned, Workout_Frequency (days/week), Experience_Level** — totalizando 9 variáveis em 973 amostras.

4 IMPLEMENTAÇÃO

4.1 Ferramentas e Ambiente

Biblioteca / Ferramenta	Versão Mín.	Uso no Projeto
Python	3.10	Linguagem principal
pandas	2.0	Manipulação de dados e EDA
NumPy	1.24	Operações vetoriais e transformações
scikit-learn	1.3	K-Means, DBSCAN, PCA, StandardScaler, Silhouette, DBI
Matplotlib	3.7	Visualizações (Elbow, PCA, Silhouette Plot, Radar)
Seaborn	0.13	Mapa de calor de correlações
Jupyter Notebook	7.x	Ambiente interativo de execução e documentação

Tabela 4 — Ferramentas utilizadas no projeto.

4.2 Pipeline de Implementação

O pipeline completo foi implementado em Jupyter Notebook, organizado nas seguintes etapas:

- **Etapla 0 — Setup:** Importação de bibliotecas, definição de paleta de cores e parâmetros globais de visualização (DPI, estilos de eixo, grid).
- **Etapla 1 — Business Understanding:** Formalização das perguntas de investigação: (a) existência de grupos naturais por intensidade e composição corporal; (b) relação frequência × composição; (c) equidade demográfica.
- **Etapla 2 — Data Understanding:** Leitura do CSV, verificação de shape (973×15) e ausência de nulos; análise descritiva; histogramas de 9 variáveis numéricas; mapa de correlação; scatter IMC × gordura por gênero; boxplot calorias por tipo de treino.
- **Etapla 3 — Data Preparation:** Seleção das 9 features; ajuste e aplicação do StandardScaler; verificação pós-scaling (média≈0, DP≈1).
- **Etapla 4 — Modelagem K-Means:** Varredura k=2..10: WCSS, Silhouette, DBI; gráfico Elbow+Silhouette; modelo final k=3; re-mapeamento de clusters por nível de experiência médio; cálculo de centroides.
- **Etapla 5 — Análise de Clusters:** Centroides em escala original; estatísticas descritivas por cluster; Radar/Spider Chart; projeção PCA 2D; Silhouette Plot por cluster.
- **Etapla 6 — DBSCAN:** k-distance plot para estimativa de ϵ ; varredura de parâmetros ($\epsilon \in \{0,5-2,0\} \times \text{MinPts} \in \{3,5,10\}$); modelo final $\epsilon=1,5$, MinPts=5; análise de outliers; visualização comparativa K-Means vs DBSCAN no PCA.

- **Etapas 7 — Fairness:** Crosstab gênero × cluster; desvio da proporção global; taxa de outlier DBSCAN por gênero; Disparate Impact Ratio; gráficos de fairness.
- **Etapas 8 — Explicabilidade:** Variância dos centroides por feature (proxy de importância); crosstab cluster × Experience_Level; sobreposição de distribuições por feature; barras de métricas por cluster com erro padrão.
- **Etapas 9 — Avaliação Crítica:** Experimento ablativo: re-clustering sem Experience_Level e Workout_Frequency; análise de sobreposição das distribuições; tabela de pontos fortes e limitações.
- **Etapas 10 — Conclusões:** Perfis textuais dos três clusters; síntese das diretrizes de IA responsável; trabalhos futuros.

4.3 Decisões Técnicas Relevantes

Escolha de $k=3$ sobre $k=2$: O Silhouette Score máximo ocorre em $k=2$ (0,268). A escolha de $k=3$ foi motivada pela interpretabilidade do domínio (alinhamento com os 3 níveis de experiência), pela maior granularidade para personalização e pelo Elbow suave em $k=3$. Esta tensão entre otimização matemática e utilidade prática foi documentada explicitamente.

$n_{\text{init}}=10$ no K-Means: O algoritmo K-Means é sensível à inicialização aleatória. Dez inicializações independentes garantem que o resultado reportado seja o melhor encontrado em múltiplos pontos de partida, reduzindo o risco de ótimo local.

Re-mapeamento dos clusters: Os índices de cluster atribuídos pelo K-Means são arbitrários. Após o fit, remapeamos os clusters em ordem crescente de Experience_Level médio, garantindo que Cluster 0 = Iniciantes, 1 = Intermediários, 2 = Avançados de forma reprodutível.

Parâmetros DBSCAN ($\epsilon=1,5$, $\text{MinPts}=5$): O ϵ foi escolhido via k-distance plot ($k=5$), identificando o "joelho" da curva de distâncias ordenadas. $\text{MinPts}=5$ é a recomendação clássica para dados com $n>100$ e dimensionalidade moderada (Ester et al., 1996).

PCA apenas para visualização: A PCA foi usada exclusivamente para projeção 2D dos pontos e centroides, não para redução de dimensionalidade antes do clustering. PC1+PC2 explicam ~47% da variância, suficiente para visualização orientativa sem distorcer os resultados do modelo principal.

5

RESULTADOS EXPERIMENTAIS

5.1 Experimento 1 — Otimização de k (K-Means)

A varredura de k=2 a k=10 produziu as seguintes métricas. O Silhouette Score máximo ocorre em k=2, enquanto a estabilização do WCSS (Método do Cotovelo) é mais suave, com inflexão visível em k=3:

k	WCSS (Inércia)	Silhouette Score	Davies-Bouldin Index
2	6.666	0.268 (máx.)	1.358
3	5.968	0.154 (escolhido)	2.249
4	5.521	0.155	2.073
5	5.157	0.146	1.963
6	4.921	0.145	1.954
7	4.718	0.147	1.908
8	4.530	0.142	1.877
9	4.360	0.137	1.921
10	4.216	0.140	1.835

Tabela 5 — Métricas de avaliação do K-Means para k=2 a 10.

■ **Nota crítica:** A escolha de k=3 representa um compromisso explícito entre performance matemática (Silhouette máximo em k=2) e interpretabilidade de domínio (3 perfis alinhados com os níveis de experiência do dataset). Esta tensão é documentada como limitação do modelo.

5.2 Experimento 2 — Modelo Final K-Means (k=3)

Atributo	Iniciantes (n=365)	Intermediários (n=417)	Avançados (n=191)
% do total	37,5%	42,9%	19,6%
Idade (anos)	~39	~39	~38
IMC	24,5	25,4	24,7
Fat_Percentage (%)	27,7	27,2	14,8
Avg_BPM (batimentos/min)	143	145	143
Calories_Burned (kcal)	714	908	1.265

Atributo	Iniciantes (n=365)	Intermediários (n=417)	Avançados (n=191)
Workout_Frequency (dias/sem)	2,5	3,5	4,5
Experience_Level	1,00	2,00	3,00

Tabela 6 — Centroides dos clusters K-Means em escala original.

5.3 Experimento 3 — Varredura de Parâmetros DBSCAN

ϵ (epsilon)	MinPts	Clusters Densos	Outliers	% Ruído
0,5	3	146	18	1,8%
0,5	5	57	62	6,4%
0,5	10	6	325	33,4%
1,0	3	23	2	0,2%
1,0	5	14	6	0,6%
1,0	10	7	21	2,2%
1,5	3	13	5	0,5%
1,5	5	10	333	34,2%
1,5	10	5	434	44,6%
2,0	3	7	1	0,1%
2,0	5	5	6	0,6%
2,0	10	3	50	5,1%

Tabela 7 — Varredura de parâmetros DBSCAN. Configuração escolhida: $\epsilon=1,5$, MinPts=5.

O modelo DBSCAN final com $\epsilon=1,5$, MinPts=5 identificou 10 clusters densos e 333 outliers (34,2% do dataset). A alta taxa de ruído indica que o DBSCAN não é adequado como método principal de segmentação neste dataset, mas é valioso para detecção de anomalias e para a análise de fairness.

5.4 Experimento 4 — Métricas Resumidas de Avaliação

Métrica	K-Means k=2	K-Means k=3	DBSCAN ($\epsilon=1,5$)
Silhouette Score	0.268 (máx.)	0.154	N/A (34,2% ruído)
Davies-Bouldin Index	1.358 (melhor)	2.249	N/A
WCSS / Inércia	6.666	5.968	N/A

Métrica	K-Means k=2	K-Means k=3	DBSCAN ($\epsilon=1,5$)
Clusters encontrados	2	3	10 + ruído
Outliers identificados	0	0	333 (34,2%)
Concordância c/ Exp. Level	Parcial	97%+	N/A
Fairness (Disparate Impact)	—	$\approx 1,0$ (aprovado)	0,63 (atenção)

Tabela 8 — Comparativo de métricas entre os modelos avaliados.

6 ANÁLISE DOS RESULTADOS

6.1 Interpretação dos Três Clusters

Cluster 0 — Iniciantes (37,5% · n=365)

Treino 2–3×/semana, média de 714 kcal/sessão e gordura corporal de 27,7%. Os parâmetros cardiovasculares (Avg_BPM=143, Resting_BPM similar aos demais) são indistinguíveis dos outros grupos, confirmando que a separação é **primariamente comportamental (frequência e experiência), não fisiológica**. O Experience_Level=1,00 indica correspondência quase perfeita com o rótulo de campo.

Cluster 1 — Intermediários (42,9% · n=417)

Treino 3–4×/semana e 908 kcal/sessão. Representa a transição: maior volume de treino que iniciantes, mas sem redução perceptível de gordura (27,2% vs 27,7%). É o grupo mais numeroso e de maior heterogeneidade interna (maior DP nas variáveis), sugerindo que "intermediário" captura uma faixa ampla de progressão, não um perfil homogêneo.

Cluster 2 — Avançados (19,6% · n=191)

Treino 4–5×/semana e 1.265 kcal/sessão. **A gordura corporal de 14,8% é a maior separação observada** — 13 pp abaixo dos demais. Dentro deste cluster, 78 membros têm IMC>25 com gordura<20%, perfil consistente com hipertrofia (massa muscular elevada). Este é o único cluster com diferença fisiológica genuína, não apenas comportamental.

6.2 Achado Crítico: A Questão das Features Âncora

A análise de variância dos centroides revelou que Experience_Level (var=1,22) e Workout_Frequency (var=0,86) são as duas features com maior poder discriminativo — muito acima das demais (BMI=0,002, Avg_BPM=0,001). Isso levanta uma questão metodológica fundamental:

■ **Possível tautologia:** se Experience_Level está nas features de clustering e os 3 clusters correspondem quase perfeitamente aos 3 valores desta variável, o K-Means pode estar "re-descobrimdo" uma partição pré-existente em vez de identificar estrutura verdadeiramente latente nos dados biométricos.

Para investigar este risco, realizamos um experimento ablativo removendo Experience_Level e Workout_Frequency das features. O resultado:

Configuração	Silhouette Score	Concordância c/ Exp. Level
Com Experience_Level + Workout_Freq.	0.154	> 97%

Configuração	Silhouette Score	Concordância c/ Exp. Level
Sem as features âncora	0.112 (redução)	~60-70% (mais mistura)

Tabela 9 — Experimento ablativo: impacto da remoção de features âncora.

Sem as features âncora, o clustering ainda recupera parcialmente os níveis de experiência (evidência de estrutura real nos dados biométricos), mas com maior mistura. Isso confirma que há sinal latente nos dados de composição corporal, mas a separação perfeita depende das features discretizadas.

6.3 Análise de Sobreposição das Distribuições

Feature	Poder de Separação	Observação
Fat_Percentage	Separação parcial	Avançados (14,8%) se separam bem dos demais (~27%). Iniciantes e Intermediários têm distribuições quase idênticas.
Calories_Burned	Boa separação	Três distribuições claramente deslocadas. É a feature com maior variação absoluta entre centroides.
Avg_BPM	Alta sobreposição	Distribuições praticamente idênticas nos três clusters (média ≈ 143 – 145). Não contribui para separação — Workout_Frequency domina.
BMI	Sem separação	Variância entre centroides $\approx 0,002$. IMC é determinado pela combinação de peso e altura, não por intensidade de treino.

Tabela 10 — Poder de separação das principais features por cluster.

7 INTEGRAÇÃO DAS DIRETRIZES DE IA RESPONSÁVEL

As duas diretrizes de IA responsável selecionadas não foram tratadas como adendo conceitual ao projeto — foram operacionalizadas em análises quantitativas concretas que influenciaram decisões de modelagem e de interpretação.

7.1 Diretriz 1 — Justiça e Viés (Fairness)

Por que é pertinente:

Algoritmos de clustering aplicados à personalização de treino podem discriminar grupos demográficos de forma não intencional — colocando mulheres ou idosos desproporcionalmente em grupos rotulados como "de baixo desempenho", reforçando estigmas. Em dados sintéticos, este risco é amplificado: correlações entre gênero e performance podem ser artefatos da geração dos dados em vez de reflexos de diferenças fisiológicas reais.

Como foi incorporada:

Realizamos dois testes quantitativos de fairness, com análise comparativa em relação a thresholds da literatura:

Teste	Métrica	Resultado	Limiar	Avaliação
Distribuição de gênero por cluster K-Means	Desvio máximo da proporção global (50/50)	~48% F / 52% M em todos os clusters (desvio máx. < 4 pp)	Sem limiar formal (referência: proporção global 47,5% F)	APROVADO Sem viés detectado
Taxa de outlier DBSCAN por gênero	Disparate Impact Ratio (DI)	Homens: 41,5% outlier Mulheres: 26,2% outlier DI = 0,63	DI >= 0,80 (Regra dos 4/5)	ATENCAO Viés potencial

Tabela 11 — Resultados quantitativos das análises de fairness.

Impactos, limitações e trade-offs:

- **K-Means:** A distribuição de gênero equilibrada nos três clusters confirma que o algoritmo não discriminou baseado em gênero como feature oculta. Este resultado era esperado, pois gênero foi deliberadamente excluído das features de clustering.
- **DBSCAN:** O Disparate Impact de 0,63 indica que homens têm 37% menos chance de serem considerados "membros de cluster denso" em comparação com mulheres — abaixo do limiar de 0,80 (80%). Investigamos três hipóteses: (a) homens têm maior variabilidade intra-grupo em treinos de força; (b) o dataset sintético pode ter gerado padrões de treino masculino mais dispersos; (c) o $\epsilon=1,5$ pode ser sub-ótimo para a geometria de clusters masculinos.
- **Trade-off explícito:** Para corrigir o viés do DBSCAN, poderíamos estratificar a análise por gênero (ϵ separado por grupo) ou remover a heterogeneidade via PCA antes do DBSCAN. Ambas as soluções foram identificadas como trabalho futuro, pois alteram fundamentalmente a configuração experimental comparável ao K-Means.

7.2 Diretriz 2 — Explicabilidade

Por que é pertinente:

Em aplicações de saúde e fitness, um praticante ou profissional de educação física precisa entender por que um usuário foi classificado em determinado grupo para que o resultado tenha valor prático. Uma segmentação "caixa-preta" não permite intervenções específicas nem construção de confiança no sistema. Além disso, a explicabilidade é essencial para detectar problemas metodológicos (como a tautologia das features âncora) que seriam invisíveis sem análise crítica.

Como foi incorporada:

Três mecanismos de explicabilidade foram implementados:

- **Análise de importância de features via variância dos centroides:** A variância entre os centroides de cada feature (no espaço normalizado) foi usada como proxy de sua importância para a separação dos clusters. Resultado: Experience_Level (1,22) e Workout_Frequency (0,86) são as principais responsáveis pela separação; Avg_BPM (0,001) e BMI (0,002) praticamente não contribuem.
- **Spider Chart (gráfico de radar) dos centroides:** O radar normalizado (0–1) de 7 features-chave permite visualizar o perfil completo de cada cluster de forma intuitiva. Um educador físico pode interpretar o gráfico sem conhecimento técnico de clustering.
- **Validação cruzada com variável de domínio:** O crosstab Cluster × Experience_Level confirmou concordância >97%. Isso significa que o modelo é explicável em termos de conceitos do domínio: "você está no Cluster 2 porque tem experiência nível 3 e treina 4–5×/semana".

Impactos, limitações e trade-offs:

A explicabilidade gerou o achado mais crítico do projeto: ao revelar que Experience_Level domina o clustering, ela expôs o risco de tautologia. Este é um exemplo de como a diretriz de explicabilidade serve não apenas para comunicação com usuários finais, mas também como instrumento de auditoria do próprio processo de modelagem. O trade-off identificado é que maior explicabilidade (3 clusters interpretáveis) exigiu a inclusão de features discretas que reduzem a "descoberta genuína" do algoritmo.

8 CONCLUSÕES E PERSPECTIVAS

8.1 Síntese dos Resultados

O projeto atingiu seus objetivos centrais: identificar perfis latentes de praticantes de exercícios e avaliá-los sob as lentes de IA responsável. Os principais achados foram:

- **Três perfis latentes foram identificados:** K-Means com $k=3$ segmentou os 973 membros em Iniciantes (37,5%), Intermediários (42,9%) e Avançados (19,6%), com concordância $>97\%$ com os rótulos de Experience_Level do dataset. A separação é primariamente comportamental (frequência e experiência), não fisiológica — com exceção da gordura corporal dos Avançados (14,8% vs $\sim 27\%$).
- **A gordura corporal é o único diferencial fisiológico genuíno:** Avançados têm Fat_Percentage 13 pp abaixo dos demais grupos. IMC, BPM e idade são quase idênticos entre os clusters — confirmando que a intensidade de treino, neste dataset, não se traduz linearmente em melhoria de todos os parâmetros biométricos.
- **Alta frequência correlaciona-se com menor gordura corporal:** A hipótese do projeto foi parcialmente confirmada: praticantes que treinam 4–5×/semana (Avançados) têm composição corporal significativamente diferente. Porém, a causalidade não pode ser estabelecida com dados transversais.
- **Fairness: K-Means aprovado, DBSCAN requer atenção:** K-Means produziu distribuição de gênero equilibrada. DBSCAN apresentou Disparate Impact de 0,63 (abaixo de 0,80), com homens 15 pp mais propensos a serem marcados como outliers — resultado que demanda investigação das causas antes de qualquer aplicação.
- **Explicabilidade revelou risco metodológico:** A análise de importância de features demonstrou que Experience_Level domina o clustering, levantando a questão de tautologia. O experimento ablativo confirmou existência de sinal latente nas features biométricas, mas a separação perfeita depende de variáveis discretizadas.

8.2 Limitações Identificadas

- **Dataset sintético ou semi-sintético:** A distribuição perfeitamente discreta do Experience_Level e a ausência de documentação sobre coleta real sugerem que os padrões descobertos podem ser artefatos da geração dos dados, não comportamentos biológicos reais.
- **Dados transversais (não longitudinais):** O dataset representa um snapshot único de cada membro. Não é possível inferir evolução temporal, resposta a treino ou causalidade entre frequência e composição corporal.
- **Silhouette Score baixo (0,154 em $k=3$):** Indica sobreposição moderada entre os clusters, especialmente entre Iniciantes e Intermediários. Os clusters não são "bolhas separadas" no espaço de features.
- **DBSCAN inadequado como método principal:** 34,2% de outliers é excessivo para segmentação — significa que um terço dos usuários não pertenceria a nenhum perfil. O algoritmo é útil para detecção de anomalias, não para segmentação completa.

- **Ausência de dados reais para validação externa:** Sem um dataset de referência com rótulos de desempenho real (ex: progresso mensurado ao longo de 6 meses), a qualidade prática da segmentação não pode ser validada externamente.

8.3 Perspectivas e Trabalhos Futuros

- Aplicar **Gaussian Mixture Models (GMM)** para capturar clusters com sobreposição suave, sem a suposição de clusters esféricos do K-Means.
- Realizar **PCA antes do clustering** para reduzir a dimensionalidade e investigar se features latentes produzem segmentação menos dependente das âncoras.
- **Remover Experience_Level e Workout_Frequency** como features de modelagem e retestar, para avaliar a descoberta genuinamente latente nas variáveis biométricas.
- Investigar o **viés de gênero no DBSCAN** com técnicas de debiasing (ε estratificado por gênero ou aplicação de reweighting antes da análise de densidade).
- Validar o modelo com **dados reais de academia** com documentação clara de coleta, incluindo evolução longitudinal dos membros ao longo de pelo menos 6 meses.
- Implementar um **dashboard interativo** que permita ao usuário inserir seus dados e receber a classificação com explicação textual das features determinantes.
- Explorar **K-Prototypes** (método original da proposta) com uma versão do dataset que inclua Workout_Type como feature categórica no clustering.

R REFERÊNCIAS

- [1] Barocas, S., Hardt, M., & Narayanan, A. (2019). *Fairness and Machine Learning: Limitations and Opportunities*. fairmlbook.org.
- [2] Doshi-Velez, F., & Kim, B. (2017). Towards a rigorous science of interpretable machine learning. *arXiv:1702.08608*.
- [3] Ester, M., Kriegel, H.-P., Sander, J., & Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. In *KDD-96 Proceedings* (pp. 226–231). AAAI Press.
- [4] Huang, Z. (1998). Extensions to the k-means algorithm for clustering large data sets with categorical values. *Data Mining and Knowledge Discovery*, 2(3), 283–304.
- [5] Jain, A. K. (2010). Data clustering: 50 years beyond K-means. *Pattern Recognition Letters*, 31(8), 651–666.
- [6] Kaggle. (2024). Gym Members Exercise Dataset. Disponível em: kaggle.com/datasets/valakhorasani/gym-members-exercise-dataset. (Reconhecido como recurso acadêmico com ressalvas de procedência.)
- [7] MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. In *Proceedings of the 5th Berkeley Symposium on Mathematics, Statistics and Probability* (Vol. 1, pp. 281–297).
- [8] Rousseeuw, P. J. (1987). Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53–65.
- [9] Schubert, E., Sander, J., Ester, M., Kriegel, H.-P., & Xu, X. (2017). DBSCAN revisited, revisited. *ACM Transactions on Database Systems*, 42(3), 1–21.
- [10] Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. In *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*.

*Relatório Final — Grupo 10 · Lucas A. Pires · John Wesley O. Costa · Emmanuel M. Figueiredo · Bernardo V. Cunha ·
Universidade Federal de Minas Gerais (UFMG) · Disciplina: Mineração de Dados · Junho 2026*