

Universidade Federal de Minas Gerais (UFMG)

Alunos: Lucas Affonso Pires, John Wesley Otaciano Costa, Emmanuel Magalhães Figueiredo, Bernardo Venâncio Cunha.

Grupo: 10

Proposta de Trabalho Prático 1 (TP1) - Mineração de Padrões Frequentes

Contexto e Hipóteses

Contexto e Hipóteses: O contexto escolhido é a análise do mercado de transferências e da performance de jogadores profissionais de futebol. O dataset a ser utilizado (`fifa_player_performance_market_value.csv`) contém informações demográficas, contratuais e de desempenho de 2.800 atletas. Nossa principal **hipótese** é a de que existem combinações frequentes de características (como faixas de idade avançada, alta propensão a lesões e curto tempo de contrato restante) que estão fortemente associadas a altos níveis de risco de transferência (*transfer risk level*) ou a faixas específicas de valor de mercado.

Abaixo, detalhamos a proposta baseada no framework CRISP-DM:

1. Qual a tarefa a ser executada? (*Entendimento do Negócio / Objetivos de Mineração de Dados*)

A tarefa consiste na aplicação de algoritmos de mineração de padrões frequentes e extração de regras de associação (como Apriori ou FP-Growth) para descobrir relações e padrões ocultos entre os atributos dos jogadores. O objetivo é identificar que conjunto de características frequentemente co-ocorrem em jogadores classificados com alto risco de transferência ou que definem jogadores de altíssimo valor de mercado.

2. Quais dados vão ser utilizados? (*Entendimento dos Dados*)

Será utilizado o dataset `fifa_player_performance_market_value.csv`. Ele é estruturado e contém 2.800 registros com atributos variados, abrangendo dados demográficos (como `age`, `nationality`), dados esportivos (`position`, `overall_rating`, `potential_rating`, estatísticas de jogo) e dados de negócios

(market_value_million_eur, contract_years_left, injury_prone, transfer_risk_level).

3. Por que a tarefa é relevante e significativa? (*Entendimento do Negócio*)

No universo da gestão esportiva, contratações envolvem investimentos milionários. Identificar padrões recorrentes que levam a investimentos de alto risco (ex: jogadores com perfis específicos que não rendem o esperado ou se lesionam frequentemente) tem um valor imenso. Para olheiros (*scouts*) e diretores de futebol, ter regras claras baseadas em dados históricos (ex: "Se Idade > 30 e Propensão a Lesão = Sim, então Risco de Transferência = Alto") auxilia na tomada de decisão estratégica, otimizando orçamentos e mitigando prejuízos financeiros e esportivos.

4. Como a tarefa vai ser executada? (*Preparação dos Dados e Modelagem*)

A execução seguirá os passos:

1. **Pré-processamento e Discretização:** Como os algoritmos de padrões frequentes exigem dados categóricos, variáveis contínuas precisarão ser discretizadas. Por exemplo, age será convertida em faixas (Jovem, Auge, Veterano), market_value_million_eur em categorias (Baixo, Médio, Alto), entre outras.
2. **Modelagem:** Aplicação de um algoritmo de mineração (ex: FP-Growth, por ser mais eficiente) focado em encontrar *itemsets* frequentes.
3. **Geração de Regras:** Extração de regras de associação com base nos *itemsets*, definindo limiares mínimos aceitáveis para métricas como *Suporte* (frequência do padrão), *Confiança* (probabilidade condicional) e *Lift* (força da associação).

5. Quais diretrizes de IA responsável serão utilizadas?

Com base nas diretrizes fornecidas na especificação da disciplina, selecionamos duas dimensões principais:

1. **Justiça e Viés (Fairness and Bias)**
2. **Explicabilidade (Explainability)**

6. Por que essas diretrizes são pertinentes ao problema?

- **Justiça e Viés:** O mercado de futebol pode embutir preconceitos históricos ou vieses geográficos (por exemplo, supervalorizar jogadores de determinadas

nacionalidades europeias em detrimento de atletas sul-americanos ou africanos com estatísticas similares). É vital garantir que as regras extraídas não reforcem preconceitos ou discriminem atletas baseados unicamente em sua nacionalidade.

- **Explicabilidade:** Modelos e regras gerados para gestores esportivos (que muitas vezes não são especialistas em dados) precisam ser altamente interpretáveis. Não basta apresentar números de suporte e confiança; o resultado precisa fazer sentido prático, ser auditável e ser facilmente traduzido para a linguagem de negócios do futebol.

7. Em que aspectos da solução se espera observar a diferença ao explicitar essas diretrizes para a LLM?

- **Interação de Referência (Sem diretrizes):** Espera-se que a LLM simplesmente gere o código em Python para rodar o Apriori/FP-Growth, discretize os dados de forma arbitrária (como dividir a idade em quantis matemáticos sem sentido biológico/esportivo) e liste as regras puramente baseadas nas maiores métricas de confiança, mesmo que tragam correlações espúrias ou enviesadas (ex: associar uma nacionalidade específica a risco alto).
- **Interação Guiada (Com diretrizes explícitas):** Ao exigir que a LLM atue sob as lentes de *Justiça e Viés* e *Explicabilidade*, esperamos que ela:
 - Sugira análises ativas para verificar se atributos sensíveis (como *nationality*) estão gerando regras discriminatórias, possivelmente recomendando a remoção ou tratamento desse atributo na mineração.
 - Proponha discretizações com maior significado de negócio (ex: separar jogadores Sub-20, jogadores no auge de 23-28 anos, etc.).
 - Formate e explique os resultados finais não apenas mostrando métricas estatísticas, mas fornecendo uma narrativa acionável e clara sobre as limitações dos padrões encontrados, evitando falsas causalidades (cumprindo a diretriz de explicabilidade técnica e de negócio).