

Proposta de Trabalho Prático 2 (TP2) — Agrupamento

Contexto e Hipóteses

O contexto escolhido é a análise do mercado de transferências e da performance de jogadores profissionais de futebol, dando continuidade ao trabalho desenvolvido no TP1. O dataset utilizado (**fifa_player_performance_market_value.csv**) contém informações demográficas, contratuais e de desempenho de 2.800 atletas.

Nossa principal hipótese é a de que é possível segmentar os jogadores em grupos naturais e interpretáveis a partir de suas características de desempenho, valor de mercado e perfil de risco — sem o uso de rótulos pré-definidos. Hipóteses específicas incluem:

- **H1:** Jogadores com perfis esportivos similares (**overall_rating**, **potential_rating**, estatísticas de jogo) formam clusters coesos que refletem categorias de mercado reconhecíveis (estrelas, jogadores de rotação, promessas).
- **H2:** Características de risco (**injury_prone**, **contract_years_left**, **transfer_risk_level**) e valor de mercado agrupam os jogadores em perfis distintos de investimento, úteis para decisões de contratação.
- **H3:** A segmentação por posição em campo (**position**) e faixa etária produz grupos com padrões de desempenho e valor de mercado consistentes.

1. Qual a tarefa a ser executada? (Entendimento do Negócio / Objetivos de Mineração de Dados)

A tarefa consiste na aplicação de algoritmos de **agrupamento não-supervisionado** (clustering) para identificar grupos naturais de jogadores com base em seus atributos. Diferentemente do TP1, que buscava padrões frequentes e regras de associação, aqui o objetivo é **segmentar a base de 2.800 atletas** em perfis coesos e interpretáveis, sem utilizar rótulos pré-definidos como variável-alvo.

Os objetivos específicos de mineração são:

- Descobrir grupos de jogadores com características de desempenho e valor de mercado similares, apoiando decisões de contratação e precificação.
- Identificar clusters de risco de transferência, auxiliando gestores a priorizar negociações e alocar orçamentos de forma estratégica.
- Validar se as segmentações encontradas pelo algoritmo correspondem a categorias reconhecíveis no universo do futebol profissional (ex.: craques, promessas, veteranos experientes, jogadores de reposição).

2. Quais dados vão ser utilizados? (Entendimento dos Dados)

Será utilizado o dataset `fifa_player_performance_market_value.csv`, com 2.800 registros e atributos nas seguintes categorias:

Categoria	Atributos Principais
Demográficos	age, nationality, name
Esportivos	position, overall_rating, potential_rating, estatísticas de jogo (passes, chutes, defesas, etc.)
Contratuais/Negócio	market_value_million_eur, contract_years_left, injury_prone, transfer_risk_level

Para o agrupamento, variáveis contínuas numéricas serão normalizadas (MinMaxScaler ou StandardScaler). Atributos categóricos como *position* e *nationality* receberão tratamento específico (encoding ou análise separada), e colunas com alta cardinalidade serão avaliadas quanto à sua contribuição para a qualidade dos clusters via análise de componentes principais (PCA) e seleção de features.

3. Por que a tarefa é relevante e significativa? (Entendimento do Negócio)

No universo da gestão esportiva moderna, clubes e agências investem somas milionárias em contratações, muitas vezes baseando-se em percepções subjetivas de valor. A segmentação orientada por dados oferece vantagens concretas:

- **Tomada de decisão estratégica:** Clusters de jogadores permitem que scouts e diretores de futebol identifiquem, de forma objetiva, quais atletas representam oportunidades de mercado subvalorizadas ou riscos financeiros ocultos.
- **Precificação e negociação:** Compreender em qual grupo um jogador se encaixa fornece benchmarks de valor de mercado mais justos, reduzindo assimetrias de informação nas negociações.
- **Gestão de plantel:** A segmentação facilita a identificação de lacunas no elenco (ex.: falta de jogadores no cluster 'alta performance, baixo risco') e orienta recrutamentos futuros.
- **Diferencial frente ao TP1:** Enquanto o TP1 identificou regras de associação entre atributos discretizados, o agrupamento opera diretamente sobre as distribuições contínuas dos dados, capturando nuances que discretizações arbitrárias podem ocultar.

4. Como a tarefa vai ser executada? (Preparação dos Dados e Modelagem)

A execução seguirá as etapas do CRISP-DM:

4.1 Pré-processamento e Engenharia de Features

Tratamento de valores ausentes; normalização de variáveis numéricas; codificação de variáveis categóricas (One-Hot para posição, análise de impacto de nationality); redução de dimensionalidade via PCA para visualização e melhora da qualidade dos clusters; remoção ou isolamento de outliers extremos.

4.2 Seleção e Aplicação dos Algoritmos

Serão avaliados ao menos três algoritmos de agrupamento:

- **K-Means:** Algoritmo baseline por sua eficiência e interpretabilidade. O número de clusters *k* será determinado pelo método do cotovelo (Elbow Method) e pelo coeficiente de silhueta.

- **DBSCAN:** Para identificar clusters de forma arbitrária e detectar automaticamente outliers (jogadores atípicos que não pertencem a nenhum grupo).
- **Agrupamento Hierárquico (Ward):** Para explorar a estrutura de similaridade via dendrograma, facilitando a interpretação qualitativa dos grupos.

4.3 Validação e Avaliação dos Clusters

A qualidade dos agrupamentos será avaliada por métricas internas (Coeficiente de Silhueta, Davies-Bouldin Index, Calinski-Harabasz Index) e por validação qualitativa: análise do perfil médio de cada cluster para verificar se os grupos fazem sentido no contexto do futebol (ex.: um cluster deve agrupar, coerentemente, jogadores jovens com alto potencial e valor de mercado crescente).

4.4 Interpretação e Comunicação dos Resultados

Cada cluster receberá uma descrição qualitativa (ex.: 'Cluster 1 — Estrelas Consolidadas', 'Cluster 3 — Promessas de Alto Risco'). Visualizações como scatter plots no espaço PCA, heatmaps de atributos médios por cluster e gráficos de radar serão produzidos para comunicar os resultados de forma acessível a gestores não especialistas em dados.

5. Quais diretrizes de IA responsável serão utilizadas?

Mantendo a coerência com o TP1, selecionamos as mesmas duas dimensões de IA responsável, agora aplicadas ao contexto de agrupamento:

- **Dimensão 1: Justiça e Não-Discriminação (Fairness)**
- **Dimensão 2: Explicabilidade e Transparência (Explainability)**

6. Por que essas diretrizes são pertinentes ao problema?

Justiça e Não-Discriminação

Algoritmos de agrupamento são sensíveis a atributos que funcionam como proxies de características protegidas. No contexto do futebol, a variável *nationality* pode introduzir viés geográfico nos clusters: se jogadores de determinadas nacionalidades são sistematicamente subvalorizados pelo mercado (refletindo preconceito histórico nos dados), o algoritmo pode criar grupos que codificam esse viés como se fosse um padrão natural. Isso teria consequências práticas graves — gestores utilizando esses clusters poderiam perpetuar discriminações ao avaliar atletas sul-americanos ou africanos com estatísticas equivalentes às de jogadores europeus, mas alocados em clusters de menor valor.

A diretriz de Fairness exige que analisemos ativamente a composição demográfica de cada cluster e verifiquemos se a variável *nationality* (ou outras variáveis sensíveis) está exercendo influência desproporcional na formação dos grupos.

Explicabilidade e Transparência

Clusters são, por natureza, estruturas abstratas. Um gestor esportivo que recebe como resposta 'este jogador pertence ao Cluster 4' sem compreender o que isso significa não consegue agir sobre a informação. A diretriz de Explicabilidade exige que cada cluster seja descrito de forma narrativa e acionável — com perfis médios interpretáveis, visualizações claras e limitações explicitamente comunicadas. Também impõe que a escolha do número de clusters e dos algoritmos seja justificada com evidências (métricas de validação) e não apenas com resultados aparentemente satisfatórios.

7. Em que aspectos da solução se espera observar a diferença ao explicitar essas diretrizes para a LLM?

Interação de Referência — Sem Diretrizes

Espera-se que a LLM aplique K-Means com k definido arbitrariamente (ex.: $k=3$ por conveniência), normalize os dados de forma genérica e inclua a variável `nationality` diretamente no modelo sem qualquer análise de impacto. Os clusters resultantes seriam apresentados apenas com suas médias numéricas, sem narrativa de negócio, e potencialmente refletiriam vieses geográficos não detectados. A escolha dos hiperparâmetros (como `eps` e `min_samples` do DBSCAN) seria feita sem justificativa baseada nos dados.

Interação Guiada — Com Diretrizes Explícitas

Ao exigir que a LLM opere sob as lentes de Fairness e Explainability, espera-se que ela:

- **[Fairness]** Recomende análise da distribuição de `nationality` por cluster e, caso identifique concentração desproporcional, sugira executar o agrupamento sem esse atributo ou com técnicas de debiasing, comparando os resultados.
- **[Fairness]** Proponha uma análise de paridade: verificar se jogadores de diferentes regiões geográficas com `overall_rating` equivalentes são alocados consistentemente nos mesmos clusters.
- **[Explainability]** Justifique a escolha do número de clusters com base no Elbow Method e no coeficiente de silhueta, apresentando os gráficos correspondentes, em vez de adotar um valor arbitrário.
- **[Explainability]** Produza, para cada cluster, uma descrição qualitativa em linguagem de negócio (ex.: 'Cluster 2 — Veteranos de Alto Risco: jogadores acima de 32 anos, com alta propensão a lesões e menos de 1 ano de contrato restante, cujo valor de mercado está em declínio'), além de visualizações de radar e heatmaps de atributos médios.
- **[Explainability]** Comunique explicitamente as limitações dos clusters encontrados: ausência de causalidade, sensibilidade à normalização escolhida e dependência dos dados históricos do mercado.