

Universidade Federal de Minas Gerais (UFMG)

Alunos: Lucas Affonso Pires, John Wesley Otaciano Costa, Emmanuel Magalhães Figueiredo, Bernardo Venâncio Cunha

Grupo: 10

Disciplina: Mineração de Dados

Proposta de Trabalho Prático 3 (TP3) - Classificação

Contexto e Hipóteses

O contexto escolhido é a análise preditiva do mercado de transferências e da performance de atletas virtuais, baseando-se nos atributos e mecânicas da série de jogos FIFA, dando continuidade à exploração de dados iniciada nos TPs anteriores. O dataset utilizado (*fifa_player_performance_market_value.csv*) contém informações demográficas, contratuais e de desempenho (*overall*, *potential*) de 2.800 atletas simulados.

Nossa principal hipótese é a de que é possível prever a categoria de risco de uma transferência (***transfer_risk_level***) de um jogador no jogo utilizando técnicas de classificação supervisionada, mapeando a relação entre seus atributos técnicos, características físicas e situação contratual.

- **H1:** Atributos ligados à durabilidade (*injury_prone*) e à situação contratual (*contract_years_left*) são os preditores mais fortes para classificar um jogador no nível de alto risco de transferência.
- **H2:** Jogadores virtuais com alto *potential_rating* e baixa idade (as chamadas "promessas" do Modo Carreira) têm uma probabilidade significativamente maior de serem classificados como baixo risco, independentemente do seu *overall_rating* atual.
- **H3:** Diferentes posições em campo exigem perfis de atributos distintos, fazendo com que a variável *position* exerça forte influência nas fronteiras de decisão dos modelos de classificação, especialmente em algoritmos baseados em árvores.

1. Qual a tarefa a ser executada? (Entendimento do Negócio / Objetivos de Mineração de Dados)

A tarefa consiste na aplicação de algoritmos de **classificação (aprendizado supervisionado)** para categorizar os jogadores da base de dados em diferentes níveis de risco de transferência. Diferentemente do TP2, onde o objetivo era encontrar agrupamentos naturais (não-supervisionado), o TP3 utilizará o atributo `transfer_risk_level` como variável-alvo (target).

Os objetivos específicos incluem: treinar modelos capazes de mapear padrões complexos de atributos para prever a classe de risco; avaliar o desempenho preditivo de diferentes algoritmos; e extrair a importância das features para entender quais mecânicas do jogo mais impactam a classificação de risco de um atleta.

2. Quais dados vão ser utilizados? (Entendimento dos Dados)

Será utilizado o mesmo dataset das etapas anteriores, `fifa_player_performance_market_value.csv`, reestruturado para a tarefa de classificação:

Categoria	Atributos	Papel no Modelo
Alvo (Target)	<code>transfer_risk_level</code>	Variável categórica a ser predita.
Demográficos	<code>age</code> , <code>nationality</code>	Features preditivas.
Esportivos (In-Game)	<code>position</code> , <code>overall_rating</code> , <code>potential_rating</code>	Features preditivas.
Contratuais	<code>market_value_million_eur</code> , <code>contract_years_left</code> , <code>injury_prone</code>	Features preditivas.

3. Por que a tarefa é relevante e significativa? (Entendimento do Negócio)

No contexto específico das mecânicas do FIFA (como o Modo Carreira) ou até mesmo em simulações de e-sports, o gerenciamento eficiente do orçamento do clube é vital. Prever corretamente o risco de transferência de um jogador permite otimizar recursos virtuais, evitando investimentos altos em atletas que possam desvalorizar ou não atingir o potencial esperado. Além disso, essa simulação atua como um excelente proxy acadêmico para o desenvolvimento de ferramentas de *scouting* preditivo utilizadas no futebol profissional real.

4. Como a tarefa vai ser executada? (Preparação dos Dados e Modelagem)

A execução continuará pautada na metodologia CRISP-DM:

- **Pré-processamento:** Separação em treino e teste (ex: 80/20). Aplicação de One-Hot Encoding para variáveis categóricas (como position). Balanceamento de classes utilizando técnicas como SMOTE, caso os níveis de risco (Baixo, Médio, Alto) estejam desproporcionalmente distribuídos no dataset.
- **Modelagem:** Serão treinados algoritmos de complexidades distintas, como Regressão Logística (baseline interpretável), Random Forest (robustez a não-linearidades) e Gradient Boosting / XGBoost (alta performance preditiva).
- **Avaliação:** Além da Acurácia, o foco será em métricas mais adequadas para classes possivelmente desbalanceadas, como Precision, Recall e F1-Score, além da análise detalhada da Matriz de Confusão.

5. Quais diretrizes de IA responsável serão utilizadas?

Continuaremos aplicando as duas diretrizes fundamentais definidas nas entregas anteriores, adaptadas para o paradigma de classificação supervisionada:

- **Dimensão 1:** Justiça e Não-Discriminação (Fairness)
- **Dimensão 2:** Explicabilidade e Transparência (Explainability)

6. Por que essas diretrizes são pertinentes ao problema?

Justiça e Não-Discriminação: Ao treinar um modelo para prever "risco", ele pode aprender vieses embutidos nas mecânicas de classificação originais do jogo. Por exemplo, se os desenvolvedores do FIFA, historicamente, associam *nationality* (nacionalidades específicas) a menores *potential_ratings* ou maiores riscos de lesão, o

modelo pode passar a classificar atletas de certas regiões com alto risco de forma injusta. A diretriz garante que avaliemos a paridade preditiva e removamos proxies discriminatórios.

Explicabilidade e Transparência: Um modelo que atinge 90% de acurácia, mas atua como uma "caixa preta", tem pouco valor analítico. Para um "manager", é fundamental saber *o que* torna a transferência de um atleta arriscada. A explicabilidade garante que possamos abrir a caixa preta (usando métodos de feature importance) e comunicar decisões acionáveis e compreensíveis a partir dos dados do jogo.

7. Em que aspectos da solução se espera observar a diferença ao explicitar essas diretrizes para a LLM?

Sem Diretrizes (Interação Genérica)	Com Diretrizes (IA Responsável)
• A LLM sugerirá treinar os modelos incluindo a variável nationality sem questionar possíveis vieses algorítmicos. • A avaliação será baseada apenas na Acurácia global, ignorando o desempenho do modelo em prever classes minoritárias (ex: jogadores de risco extremo). • Os resultados finais focarão apenas em qual algoritmo teve o melhor score, não explicando como o modelo toma suas decisões.	• [Fairness] Espera-se que a LLM conduza uma análise de paridade demográfica sobre nationality, sugerindo métricas de Fairness para garantir que as taxas de falsos positivos (alto risco incorreto) sejam equilibradas entre as nacionalidades. • [Explainability] A LLM deverá implementar técnicas como SHAP values ou LIME para demonstrar a importância global e local das features, explicando as mecânicas por trás de cada predição. • [Explainability] Sugerirá focar o relatório de avaliação em métricas granulares (Classification Report completo) e curvas ROC/PR, traduzindo as saídas matemáticas em insights de recrutamento esportivo virtuais.